JKSCI

한국컴퓨터정보학회논문지
Journal of The Korea Society of Computer and Information
Vol. 24 No. 1, pp. 0-0, January 2019
https://doi.org/10.9708/jksci.2019.24.01.000

Performance Improvement of Recommendation Systems using User Evaluation Information

Hee-Chan Kim *, Yun-suk Kwak **, Namgi Kim ***

*Student, Kyonggi University, Suwon, Korea
**Student, Kyonggi University, Suwon, Korea
***Professor, Kyonggi University, Suwon, Korea

[Abstract]

Graph Signal Processing (GSP)-based recommender systems have attracted attention due to their high computational efficiency compared with Graph Convolutional Network (GCN)-based approaches. Howeve r, existing GSP-based methods do not explicitly utilize user rating information when constructing interact ion graphs. To address this limitation, this paper proposes a Rating-Aware Graph Filtering method that i ncorporates user ratings into graph filtering. The proposed method was evaluated on five benchmark dat asets: ML-100K, ML-Latest-Small, ML-1M, FilmTrust, and CiaoDVD. Experimental results show consist ent improvements over HiGSP, achieving up to 4.90% improvement in F1@5, 11.03% improvement in MRR@10, and 9.31% improvement in NDCG@10. These results demonstrate that incorporating user rati ng information effectively enhances recommendation performance in GSP-based recommender systems.

▸ **Key words** : Recommendation system, Graph signal processing, Graph filtering, User rating, HiGSP

[요 약]

그래프 신호 처리(Graph Signal Processing, GSP) 기반 추천시스템은 그래프 합성곱 신경망(Graph Convolutional Network, GCN) 기반 추천시스템에 비해 높은 연산 효율성을 제공하지만, 사용자 평점 정보를 직접적으로 반영하지 못하는 한계를 가진다. 본 논문에서는 사용자 평점을 반영한 Rati ng-Aware Graph Filtering 기법을 제안하며, 평점 기반 인접행렬과 기존 상호작용 기반 인접행렬을 결합하여 그래프 필터링을 수행한다. 제안 기법의 성능 검증을 위해 ML-100K, ML-Latest-Small, M L-1M, FilmTrust, CiaoDVD 데이터셋에서 실험을 수행하였다. 실험 결과, 기존 HiGSP 모델 대비 최대 F1@5는 4.90%, MRR@10은 11.03%, NDCG@10은 9.31% 향상되었으며, 이를 통해 사용자 평점 정보를 활용한 그래프 필터링이 추천 성능 향상에 효과적임을 확인하였다.

▸ **주제어** : 추천시스템, 그래프 신호 처리, 그래프 필터링, 사용자 평점, HiGSP

• First Author: Hee-Chan Kim, Corresponding Author: Namgi Kim
*Hee-Chan Kim(이메일@kyonggi.ac.kr), Kyonggi University
**Yun-suk Kwak(lukeyun@kyonggi.ac.kr), Kyonggi University
***Namgi Kim(ngkim@kyonggi.ac.kr), Kyonggi University
"This paper is an extended version of a paper presented at the IEEE ICUFN held in Lisbon, Portugal in 2025."
• Received: 2019. 01. 01, Revised: 2019. 01. 10, Accepted: 2019. 01. 20.

Copyright © 2019 The Korea Society of Computer and Information
http://www.ksci.re.kr pISSN:1598-849X | eISSN:2383-9945

I. Introduction

최근 인터넷 환경의 빠른 발전과 모바일 기기의 보급으로 인해 다양한 정보와 콘텐츠의 양이 폭발적으로 증가하고 있다. 특히 전자상거래 서비스, 스트리밍 서비스, 소셜 미디어 서비스 등 다양한 서비스 분야에서의 시장이 성장함에 따라 제공되는 상품과 콘텐츠가 넘쳐나면서 사용자들이 자신에게 맞는 선택을 하는 것이 점점 더 어려워지고 있다. 이러한 배경으로 인해 사용자의 선택을 도와줄 기술인 추천시스템이 등장하였다. 추천 시스템은 정보 필터링(Information Filtering) 기술의 일종으로, 사용자가 관심을 가질 만한 정보를 사용자에게 추천함으로써 사용자의 만족도를 높이는 것을 목표로 한다 [1][2][3][4]. 따라서 추천 시스템은 정보 과부하 문제를 해소하는데 기여하며, 사용자와 서비스 제공자 모두에게 긍정적인 가치를 제공한다.

추천시스템에서 가장 중요한 두 가지 요소는 학습 속도와 정확도이다. 추천시스템에서의 학습 속도는 새로운 데이터에 대해 추천시스템 모델이 얼마나 빠르게 학습하여 사용자에게 적합한 정보를 실시간으로 제공할 수 있는 지를 의미한다. 사용자의 선호도와 행동 패턴은 시간에 따라 빠르게 변하기 때문에 추천 시스템이 이러한 변화를 빠르게 반영하지 못하면 사용자에게 오래된 정보를 제공하게 되어 사용자의 만족도를 저하시키는 요인이 된다. 또, 추천시스템에서의 정확도는 추천 시스템이 사용자에게 얼마나 관련성이 높고 적절한 정보를 제공하는 지 나타내는 중요한 지표이다. 정확도가 높은 추천 시스템은 사용자의 취향을 잘 반영하여 개인 맞춤형 콘텐츠를 제공할 수 있다 [5][6][7][8][9][10].

이를 위해 본 연구는 그래프 신호 처리(Graph Signal Processing, GSP) 기반 추천시스템에서 사용자의 평점을 반영하여 성능을 향상시키는 새로운 방법을 제안한다. 기존 그래프 합성곱 신경망(Graph Convolution Network, GCN)기반 추천시스템은 그래프 합성곱 연산을 통해 복잡한 그래프 구조를 효과적으로 다룰 수 있지만, 가중치 매개변수가 많고 이를 최적화시키는데 소요되는 학습시간이 매우 길다는 한계가 있다 [12][13][14][15][16]. 이에 추천시스템 모델 업데이트에 걸리는 시간이 길다는 단점이 존재한다. 이를 극복하기 위해, 보다 단순한 관계를 처리하는데 효율적인 그래프 신호 처리 기반 추천시스템이 등장하였다 [17][18][19][20][21][22].

그래프 신호 처리 기반 추천시스템은 Low-pass Filter를 통해 연산을 수행하는데 이는 단순한 행렬 연산으로 가중치 매개변수의 학습이 필요 없어 빠르게 연산이 가능하다. 따라서 추천시스템 모델을 빠르게 업데이트 할 수 있다. 정확도 또한 그래프 합성곱 신경망 기반 추천시스템과 비교해보았을 때 비슷하거나 더 높은 수치를 보인다 [19][20][21][22].

하지만 기존 그래프 신호 처리 기반 추천시스템에서는 사용자가 높은 평점을 준 아이템과 낮은 평점을 준 아이템에 대해 차등을 두지 않고 동등하게 모델에 반영한다 [22]. 따라서 본 연구에서는 보다 개인화된 추천을 위해 높은 사용자의 평점을 모델에 반영하는 방법을 제안한다.

II. Related Works

추천 시스템은 콘텐츠 기반 필터링(Content-Based Filtering), 협업 필터링(Collaborative Filtering), 그리고 두 방식을 결합한 하이브리드 필터링(Hybrid Filtering)으로 구분된다 [1][2][3][4].

콘텐츠 기반 필터링은 아이템 자체의 특징에 초점을 두어 사용자가 과거에 선호한 아이템과 유사한 특성을 가진 아이템을 추천하는 방식이다. 다른 사용자 데이터 없이도 추천이 가능하다는 장점이 있으나, 아이템의 특징을 정의하고 추출하는 과정이 어렵고 사용자의 다양한 관심사를 충분히 반영하기 어렵다는 한계가 있다.

협업 필터링은 유사한 선호도를 가진 사용자들이 다른 아이템에 대해서도 유사한 선호를 보일 것이라는 가정에 기반한 추천 기법이다 [3][5][6][8][9][10][11]. 이는 사용자 간 유사성을 활용하는 사용자 기반 협업 필터링과 아이템 간 유사성을 활용하는 아이템 기반 협업 필터링으로 구분된다 [7]. 협업 필터링은 아이템의 특징 정보 없이도 추천이 가능하고 사용자의 관심사를 확장할 수 있으나, 새로운 사용자 또는 아이템에 대한 데이터가 부족한 콜드 스타트 문제(Cold Start Problem)와 데이터 희소성 문제(Data Sparsity Problem)에 취약하다. 또한 사용자-아이템 상호작용 데이터가 증가할수록 연산량이 증가하는 단점이 있다.

하이브리드 필터링은 콘텐츠 기반 필터링과 협업 필터링의 장점을 결합하여 추천 성능을 향상시키는 방법이다. 특히 콘텐츠 기반 필터링을 활용하여 협업 필터링의 콜드 스타트 문제를 완화할 수 있으며, 충분한 상호작용 데이터가 확보된 이후에는 협업 필터링을 적용하여 추천의 다양

JKSCI
한국컴퓨터정보학회논문지
Journal of The Korea Society of Computer and Information
Vol. 24 No. 1, pp. 0-0, January 2019
https://doi.org/10.9708/jksci.2019.24.01.000

성을 확보할 수 있다. 그러나 모델 구조가 복잡하고 연산 비용이 증가한다는 한계가 존재한다.

딥러닝 기반 협업 필터링의 발전 이후 그래프 합성곱 신경망(Graph Convolution Network, GCN)을 추천 시스템에 적용하려는 연구가 활발히 진행되었다 [12]. 대표적인 모델로는 NGCF [13], LightGCN [14], SimGCL [15], XSimGCL [16] 등이 있다.

그래프 신호 처리(Graph Signal Processing, GSP)는 기존 신호 처리의 개념을 그래프 구조로 확장한 방법으로, 그래프의 구조적 특성을 활용하여 데이터를 분석한다 [17][18]. 주요 개념으로는 그래프 신호(Graph Signal), 그래프 라플라시안 행렬(Graph Laplacian Matrix), 그래프 필터링(Graph Filtering), 그래프 푸리에 변환(Graph Fourier Transform, GFT)이 있다. 그래프 라플라시안 행렬은 고유값 분해를 통해 그래프 상의 주파수 특성을 정의하며, 이를 기반으로 주파수 영역에서의 필터링을 수행할 수 있다.

그래프 필터링은 그래프 신호를 주파수 영역으로 변환한 뒤 특정 주파수 성분을 강조하거나 제거하는 과정이다. 특히 Low-pass Filter는 고주파 성분을 제거하여 노드 간 유사성을 강조하는 데 활용된다. 일반적인 그래프 필터링 과정은 그래프 신호 정의, 라플라시안 행렬 계산, 그래프 푸리에 변환, 주파수 영역 필터링, 역변환 순서로 수행된다.

이러한 그래프 신호 처리 기법을 협업 필터링에 적용한 대표적인 모델이 GF-CF(Graph Filter based Collaborative Filtering)이다 [19]. 협업 필터링에서는 사용자 및 아이템 간 유사성을 효과적으로 반영하는 것이 중요하므로 GF-CF는 저주파 성분을 강조하기 위해 Linear Low-pass Filter와 Ideal Low-pass Filter를 활용하였다.

GF-CF 이후 다양한 후속 연구가 제안되었다. PGSP(Personalized Graph Signal Processing)는 사용자 정보를 더욱 풍부하게 반영하기 위해 그래프 구조를 재정의하였으며 [20], Turbo-CF는 GF-CF의 연산 효율성을 향상시키기 위해 제안되었다 [21]. 또한 HiGSP(Hierarchical Graph Signal Processing)는 유사한 사용자를 클러스터링한 후 그래프 필터링을 수행하는 계층적 구조를 도입하였다 [22].

본 연구는 2024년 기준 그래프 신호 처리 기반 추천시스템 중 우수한 성능을 보인 HiGSP를 기반으로 한다. HiGSP는 사용자 클러스터링을 활용한 클러스터 기반 필터 모듈과 Ideal Low-pass Filter 및 High-order Low-pass Filter로 구성된 전역 인식 필터 모듈을 결합하여 사용자 선호도를 모델링한다. 이를 통해 사용자별 상호작용 패턴을 효과적으로 반영하고 미래 선호도를 예측한다.

한편, 기존 연구 [19]에서는 그래프 합성곱 신경망 기반 모델인 LightGCN과 그래프 신호 처리 기반 모델인 GF-CF를 비교하였다. GF-CF는 학습해야 할 파라미터가 존재하지 않고 행렬 연산만으로 동작하기 때문에 복잡한 학습 과정 없이 매우 빠른 연산이 가능하다. 또한 Yelp2018과 Amazon-book 데이터셋에서는 LightGCN보다 우수한 추천 성능을 보였으며, 이를 통해 그래프 신호 처리 기반 추천시스템이 그래프 합성곱 신경망 기반 추천시스템 대비 높은 연산 효율성을 가짐을 확인할 수 있다. 따라서 본 연구에서는 그래프 신호 처리 기반 추천시스템의 장점을 유지하면서 추천 성능을 향상시키는 방법을 제안하고자 한다.

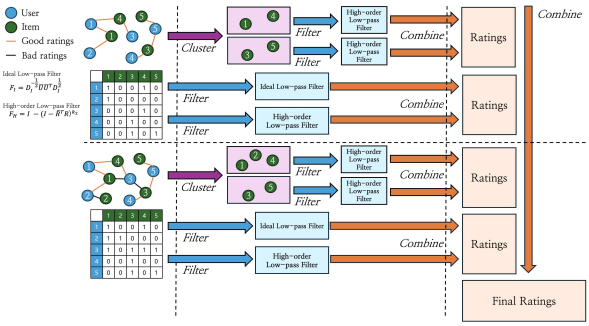
III. The Proposed Scheme

HiGSP를 포함한 기존 그래프 신호 처리 기반 추천시스템은 인접행렬 구축을 위해 User Interaction Matrix를 생성할 때 사용자의 평점 정보를 고려하지 않고, 사용자와 아이템 간 상호작용 유무만을 반영한다 [19][20][21][22]. 이는 사용자가 선호하는 아이템과 더 자주 상호작용할 것이라는 가정에 기반하지만, 실제 환경에서는 낮은 평점을 부여한 아이템과 반복적으로 상호작용하거나 높은 평점을 부여한 아이템과는 상호작용이 적은 경우도 존재한다. 따라서 단순 상호작용 정보만으로 생성된 인접행렬은 사용자의 실제 선호도를 충분히 반영하지 못할 수 있으며 추천 성능 저하로 이어질 가능성이 있다.

이에 본 연구에서는 User Interaction Matrix 생성 과정에서 사용자의 평점 정보를 추가적으로 반영하는 방법을 제안한다. 구체적으로 사용자가 아이템에 부여한 평점이 특정 기준값 N점 이상(본 연구에서는 3점 이상)인 경우에만 사용자-아이템 간 연결을 생성하여 새로운 인접행렬을 구축한다. 이를 통해 사용자가 선호하는 아이템의 신호를 강화하고 개인화된 추천 성능을 향상시키고자 한다.

그러나 평점 기반 인접행렬만 사용할 경우 낮은 평점에 포함된 정보가 제거되어 정보 손실이 발생할 수 있다. 이를 해결하기 위해 본 연구에서는 기존의 상호작용 기반 인접행렬과 평점 기반 인접행렬을 함께 활용한다. 두 인접행렬에 각각 그래프 필터링 연산을 수행한 후 결과를 가중 결합함으로써 사용자의 선호 정보를 효과적으로 반영하면

서도 정보 손실을 최소화하였다 [17][18]. 또한 이러한 결합 구조를 통해 앙상블 효과를 얻을 수 있었으며, 제5장의 실험에서는 기준 평점 N의 변화에 따른 추천 성능을 기존 모델과 비교·분석하였다.



<그림 8> 제안 모델의 구조

그림 8은 제안 모델의 전체적인 구조를 나타낸다. 그림의 구성은 크게 두 부분으로 나뉜다. 그림의 하단은 기존 HiGSP 모델의 방식과 동일하게 그래프 필터링 연산을 수행하며 그림의 상단은 본 연구에서 제안한 새로운 인접 행렬을 사용하여 그래프 필터링 연산을 수행한다 [22]. 이를 통해 정보 손실 문제를 보완하면서 보다 더 개인화된 추천 및 앙상블 효과를 누린다.

그림 8의 하단부는 제안 방법에 따른 정보 손실을 막기 위하여 기존 방법과 동일하게 인접 행렬을 구축하였다. 그 뒤 유사한 사용자들의 그룹을 형성하는 Clustering을 수행한 후 Linear Low-pass Filter를 적용하여 Ratings를 계산한다. 그 다음 기존 인접 행렬을 사용하여 각각 Ideal Low-pass Filter와 High-order Low-pass Filter을 적용하여 각각 Ratings를 계산한다 [22]. 이 과정에서 다양한 Low-pass Filter가 적용되어 사용자의 선호도를 반영한 추천 품질을 높인다.

그림 8의 상단부는 본 연구에서 제안하는 새로운 인접 행렬 구축 방식을 통해 인접행렬을 새롭게 구축하여 그래프 필터링 연산을 수행하였다. 그 뒤 하단부와 동일하게 유사한 사용자들의 그룹을 형성하는 Clustering을 수행한 후 Linear Low-pass Filter를 적용하여 Ratings를 계산한다. 그 다음 제안한 방법의 인접행렬에서 각각 Ideal Low-pass Filter와 High-order Low-pass Filter을 거쳐 Ratings을 계산한다. 이 방식을 통해 단순 상호작용이 아닌 높은 사용자의 평점을 그래프 필터링에 반영하여 보다 더 높은 정확도를 가지는 개인화 추천을 가능하게 한다. 마지막 단계에서는 위 방식을 통해 생성된 4개의 Ratings 행렬에 가중치를 주어 서로 결합하여 Final Ratings 행렬을 계산한다. 위와 같은 과정을 통해 본 연구에서는 기존 HiGSP의 단점을 보완하고 앙상블 효과도 누려 추천 성능을 더욱 극대화하고자 하였다.

IV. Experiments

<표 1> 실험에 사용한 데이터셋

Dataset	ML-100K	ML-Small	ML-1M	Film Trust	Ciao DVD
Interaction	100,000	100,836	1,000,209	35,496	72,664
Users	943	610	6,040	1,508	17,615
Items	1682	9,724	3,706	2,071	16,121
Ratings Range	[1, 5]	[0.5, 5.0]	[1, 5]	[0.5, 4.0]	[1, 5]
Density	6.305%	1.700%	4.468%	1.137%	0.026%

표 1에서 보이는 것과 같이 기존 모델과 제안 모델의 성능을 비교하기 위해 총 5개의 데이터셋을 사용하였다. 실험에 사용한 데이터셋은 ML-100K, ML-1M, ML-Latest-Small, FilmTrust, CiaoDVD이다. MovieLens 데이터셋은 GroupLens Research에서 제공하는 대표적인 추천시스템 벤치마크 데이터셋으로 사용자와 영화 간 평점 정보를 포함한다 [23]. FilmTrust는 사용자 간 신뢰 관계와 영화 평점 정보를 함께 제공하는 데이터셋으로 사회적 추천 시스템 연구에 널리 활용되고 있다 [24]. CiaoDVD는 상품 리뷰 및 평점 정보를 포함하는 데이터셋으로 사용자 선호 분석과 추천 성능 평가에 사용된다 [25]. ML-100K와 ML-1M은 선행 실험에서 사용한 데이터셋이나 보다 면밀한 분석을 위해 학습 데이터와 테스트 데이터를 새롭게 분할하여 실험을 수행하였다. 또한 ML-Latest-Small, FilmTrust, CiaoDVD는 선행 실험에서 사용되지 않은 데이터셋으로 추가적인 일반화 성능 검증을 위해 활용하였다. 데이터셋의 특성을 비교하기 위해 총 사용자 수, 총 아이템 수, 사용자-아이템 상호작용 수, 그리고 밀집도(density)를 분석하여 표 1에 제시하였다. 데이터셋의 밀집도는 아래 수식을 이용하여 계산하였다.

<표 2> 실험 환경

Resource	Property
OS	Ubuntu 22.04 LTS
CPU	13th Gen Intel(R) Core TM

JKSCI
한국컴퓨터정보학회논문지
Journal of The Korea Society of Computer and Information
Vol. 24 No. 1, pp. 0-0, January 2019
https://doi.org/10.9708/jksci.2019.24.01.000

	I9-13990K
RAM	DDR 5 32GB + 256G SWAP
GPU	NVIDIA GeForce RTX 4090

본 연구의 실험은 표 2와 같은 환경에서 표 3과 같은 패키지 버전 아래에서 수행되었다.

<표 3> 실험 환경의 패키지 버전

Package	Version
Python	3.7.10
Numpy	1.19.5
Pytorch	1.9.0
Scikit-learn	0.22.0
Scipy	1.5.2
Sparsesvd	0.2.2

<표 4> 실험에 사용한 하이퍼파라미터

Hyperparameter	Setting
alpha1	0.3
alpha2	0.7
order1	8
order2	8
pri_factor	256
n_cluster	5
HiGSP : Ours	5 : 5
random_state	2024

본 연구의 실험은 위 표 4와 같은 하이퍼파라미터를 사용해 수행하였다. alpha1은 Ideal Low-pass Filter을 적용한 ratings행렬의 가중치를 의미하고 alpha2는 High-order Low-pass Filter을 적용한 ratings 행렬의 가중치를 의미한다. order1은 클러스터링에 적용된 High-order Low-pass Filter의 계수이고, order2는 인접행렬에 적용된 High-order Low-pass Filter의 계수이다. pri_factor은 sparsesvd에 사용되는 인자로, pri_factor 개의 특이값을 사용한다는 의미한다. n_cluster은 클러스터링을 수행할 때 n_cluster 개의 그룹으로 묶어준다는 것을 의미한다. HiGSP : Ours는 기존 모델과 제안 모델을 결합할 때 부여한 가중치의 비율이다 [22]. random_state는 실험 결과의 일관성을 위해 설정하였으며 동일한 random_state로 실험을 수행하면 본 연구에서의 실험과 동일한 결과를 얻을 수 있다.

본 연구에서 그래프 신호 처리 기반의 추천시스템의 추천 성능을 높이기 위해 사용자의 평점을 반영하여 인접행렬을 새롭게 구축하고 이 인접행렬을 반영한 모델을 제안하였다. 앞서 소개한 평가지표인 F1@K, NDCG@K, MRR@K를 활용하여 기존 모델인 HiGSP와 제안 모델의 성능 비교를 수행하였다 [22].

성능 비교에 사용된 평가지표는 F1@5, F1@10, MRR@5, MRR@10, NDCG@5, NDCG@10이다. 제안 모델은 총 4가지로 각 모델은 사용자가 남긴 평점에 따라 인접행렬을 다르게 구축하였다. 구체적으로, 첫 번째 모델은 평점 2점 이상인 사용자-아이템 상호작용 데이터를 반영한 모델, 두 번째 모델은 평점 3점 이상인 사용자-아이템 상호작용 데이터를 반영한 모델, 세 번째 모델은 평점 4점 이상인 사용자-아이템 상호작용 데이터를 반영한 모델, 마지막으로 네 번째 모델은 평점 5점 이상인 사용자-아이템 상호작용 데이터를 반영한 모델이다.

실험은 총 5개의 데이터셋을 대상으로 수행되었으며 각각의 데이터셋에서 기존 모델과 제안된 4가지 모델의 성능을 비교하였다. 다만, FilmTrust는 평점 [0.5, 4]로 구성된 데이터셋이므로 해당 데이터셋에서 네 번째 모델의 결과는 제외하였다 [24].

<표 5> Ratings ≥ 2 에서의 성능 비교

Dataset	Metrics	HiGSP	Ours(≥ 2)
ML-100K	F1@5	0.2099	**0.2139 (+1.91%)**
	F1@10	0.2718	**0.2750 (+1.18%)**
	MRR@5	0.5830	**0.5971 (+2.42%)**
	MRR@10	0.5434	**0.5511 (+1.42%)**
	NDCG@5	0.6366	**0.6484 (+1.85%)**
	NDCG@10	0.6182	**0.6226 (+0.71%)**
ML-Latest-Small	F1@5	0.1001	**0.1050 (+4.90%)**
	F1@10	0.1478	**0.1501 (+1.56%)**
	MRR@5	0.3270	**0.3495 (+6.88%)**
	MRR@10	0.3421	**0.3520 (+2.89%)**
	NDCG@5	0.3977	**0.4188 (+5.31%)**
	NDCG@10	0.4439	**0.4523 (+1.89%)**
ML-1M	F1@5	0.1789	**0.1805 (+0.89%)**
	F1@10	0.2457	**0.2462 (+0.20%)**
	MRR@5	0.5984	**0.6000 (+0.27%)**
	MRR@10	**0.5603**	0.5601 (-0.04%)
	NDCG@5	0.6571	**0.6591 (+0.30%)**

	NDCG@10	0.6407	**0.6410 (+0.05%)**
FilmTrust	F1@5	0.4469	**0.4491 (+0.49%)**
	F1@10	0.4634	**0.4639 (+0.11%)**
	MRR@5	0.5930	**0.6004 (+1.25%)**
	MRR@10	**0.5474**	0.5468 (-0.11%)
	NDCG@5	0.6381	**0.6460 (+1.24%)**
	NDCG@10	0.6158	**0.6187 (+0.47%)**
CiaoDVD	F1@5	0.0080	**0.0083 (+3.75%)**
	F1@10	0.0085	**0.0092 (+8.24%)**
	MRR@5	0.0133	**0.0139 (+4.51%)**
	MRR@10	0.0136	**0.0151 (+11.03%)**
	NDCG@5	0.0166	**0.0170 (+2.41%)**
	NDCG@10	0.0204	**0.0223 (+9.31%)**

표 5는 Ratings2에서 HiGSP와 성능 비교한 표이다. 모든 데이터셋에 대해 전반적으로 높은 성능을 달성했음을 볼 수 있다.

<표 6> Ratings≥5 에서의 성능 비교

Dataset	Metrics	HiGSP	Ours(≥5)
ML-100K	F1@5	0.2099	**0.2115 (+0.76%)**
	F1@10	0.2718	**0.2728 (+0.37%)**
	MRR@5	0.5830	**0.5902 (+1.23%)**
	MRR@10	0.5434	**0.5490 (+1.03%)**
	NDCG@5	0.6366	**0.6434 (+1.07%)**
	NDCG@10	0.6182	**0.6219 (+0.6%)**
ML-Latest-Small	F1@5	0.1001	**0.1080 (+7.89%)**
	F1@10	0.1478	**0.1491 (+0.88%)**
	MRR@5	0.3270	**0.3490 (+6.73%)**
	MRR@10	0.3421	**0.3429 (+0.23%)**
	NDCG@5	0.3977	**0.4195 (+5.48%)**
	NDCG@10	0.4439	**0.4480 (+0.92%)**
ML-1M	F1@5	0.1789	**0.1804 (+0.84%)**
	F1@10	0.2457	**0.2473 (+0.65%)**
	MRR@5	0.5984	**0.6014 (+0.50%)**
	MRR@10	0.5603	**0.5625 (+0.39%)**
	NDCG@5	0.6571	**0.6607 (+0.55%)**
	NDCG@10	0.6407	**0.6427 (+0.31%)**
CiaoDVD	F1@5	0.0080	**0.0092 (+15.0%)**
	F1@10	0.0085	**0.0089 (+4.71%)**
	MRR@5	0.0133	**0.0155 (+16.54%)**
	MRR@10	0.0136	**0.0141 (+3.68%)**
	NDCG@5	0.0166	**0.0190 (+14.46%)**
	NDCG@10	0.0204	**0.0212 (+3.92%)**

표 6은 Ratings5에서 HiGSP와 성능 비교한 표이다 [22]. 모든 데이터셋에 대해 전반적으로 높은 성능을 달성했음을 볼 수 있다. 참고로, ML-Latest-Small 데이터셋에서는 HiGSP에 0.7, 제안 모델에 0.3으로 가중치를 부여해 결합하고, ML-1M 데이터셋에서는 HiGSP에 0.8, 제안 모델에 0.2으로 가중치를 부여해 결합하여 측정한 성능이다.

V. Conclusions

본 연구에서는 그래프 신호 기반의 추천시스템에서 추천 성능 향상을 달성하기 위하여 기존 HiGSP 모델의 한계를 보완하는 방법을 제안하였다 [22]. 기존 HiGSP 모델에서는 사용자가 아이템에 대해 좋은 평점을 남긴 데이터와 나쁜 평점을 남긴 데이터를 인접행렬에 구축 시 동일하게 반영하여 개인화된 추천을 방해하는 문제점이 있었다. 이러한 문제를 해결하기 위해, 본 연구에서는 사용자가 높은 평점을 남긴 아이템을 반영한 인접행렬을 기존 모델에 추가로 도입하여 사용자에게 높은 평점을 받은 아이템의 신호를 더 강하게 만들고 앙상블 효과를 가져와 사용자 선호도를 보다 더 정확히 예측하는 방법을 제안하였다.

이러한 제안을 통해 5개 데이터셋에 대해 본 연구에서 제안한 방식을 사용한 4가지 모델을 적용하여 기존 HiGSP모델과 성능을 비교하는 실험을 수행하였다. 실험 결과, 제안 모델의 Ratings2, Ratings3, Ratings4와 Ratings5 모두 5개 데이터셋에 대해 기존 모델보다 전반적으로 높은 성능을 달성하였다. 특히 CiaoDVD 데이터셋에서는 탁월한 성능을 보임을 알 수 있었다.

향후 연구로는 제안 방법에서 2개의 인접행렬을 사용하여 발생하는 추가 연산 문제를 개선하고자 한다. 이를 해결하기 위해 가중치를 반영한 1개의 인접행렬을 사용하여 더 좋은 정확도를 달성하면서 연산 성능을 높이는 연구를 진행할 예정이다.

JKSCI

한국컴퓨터정보학회논문지
Journal of The Korea Society of Computer and Information
Vol. 24 No. 1, pp. 0-0, January 2019
https://doi.org/10.9708/jksci.2019.24.01.000

ACKNOWLEDGEMENT

This work was supported by Kyonggi University's Graduate Research Assistantship 2026. This work was supported by the Institute of Information & Communications Technology Planning & Evaluation(IITP)-ICAN(ICT Challenge and Advanced Network of HRD) grant funded by the Korea government(Ministry of Science and ICT) (IITP-2024-00436954) and supported by Basic Science Research Program through the National Research Foundation of Korea(NRF) funded by the Ministry of Education (RS-2020NR049579).

REFERENCES

[1] A. I. Saleh, A. I. El Desouky, and H. A. Shereen, "Promoting the performance of vertical recommendation systems by applying new classification techniques," Knowledge-Based Systems, vol. 75, pp.192-223, 2015.

[2] M. Goyani, N. Chaurasiya, "A review of movie recommendation system: Limitations, Survey and Challenges," ELCVIA: Electronic Letters on Computer Vision and Image Analysis, vol. 19, no. 3, pp. 18-37, 2020.

[3] Y. Hu, Y. Koren, and C. Volinsky, "Collaborative Filtering for Implicit Feedback Datasets," 2008 Eighth IEEE International Conference on Data Mining, pp. 263-272, 2008.

[4] E. Çano, M. Morisio, "Hybrid Recommender Systems: A Systematic Literature Review," Intelligent Data Analysis, vol. 21, no. 6, pp. 1487-1524, 2017.

[5] D. Goldberg, D. Nichols, B. M. Oki, and D. Terry, "Using Collaborative Filtering to Weave an Information Tapestry," Communications of the ACM, vol. 35, no. 12, pp. 61-70, 1992.

[6] P. Resnick, N. Iacovou, M. Suchak, P. Bergstrom, and J. Riedl, "GroupLens: An Open Architecture for Collaborative Filtering of Netnews," Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work, pp. 175-186, 1994.

[7] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, "Item-based Collaborative Filtering Recommendation Algorithms," Proceedings of the 10th International Conference on World Wide Web, pp. 285-295, 2001.

[8] Y. Koren, R. Bell, and C. Volinsky, "Matrix Factorization Techniques for Recommender Systems," Computer, vol. 42, no. 8, pp. 30-37, 2009.

[9] P. Covington, J. Adams, and E. Sargin, "Deep Neural Networks for YouTube Recommendations," Proceedings of the 10th ACM Conference on Recommender Systems, pp. 191-198, 2016.

[10] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and T. Chua, "Neural Collaborative Filtering," Proceedings of the 26th International Conference on World Wide Web, pp. 173-182, 2017.

[11] M. Naumov, D. Mudigere, H. J. M. Shi, J. Huang, N. Sundaraman, P. Jongsoo, X. Wang, U. Gupta, C. J. Wu, A. Azzolini, D. Dzhulgakov, A. Mallevich, I. Cherniavskii, Y. Lu, R. Krishnamoorthi, A. Yu, V. Kondratenko, S. Pereira, X. Chen, and M. Smelyanskiy, "Deep Learning Recommendation Model for Personalization and Recommendation Systems," arXiv:1906.00091, 2019.

[12] T. N. Kipf and M. Welling, "Semi-supervised Classification with Graph Convolutional Networks," Proceedings of the International Conference on Learning Representations (ICLR), 2017.

[13] X. Wang, X. He, M. Wang, F. Feng, and T. S. Chua, "Neural Graph Collaborative Filtering," Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 165-174, 2019.

[14] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, "LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation," Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 639-648, 2020.

[15] C. Liu, C. Yu, N. Gui, Z. Yu, and S. Deng, "SimGCL: Graph Contrastive Learning by Finding Homophily in Heterophily," Knowledge and Information Systems, vol. 66, no. 3, pp. 2089-2114, 2023.

[16] J. Yu, X. Xia, T. Chen, L. Cui, N. Q. V. Hung, and H. Yin, "XSimGCL: Towards Extremely Simple Graph Contrastive Learning for Recommendation," IEEE Transactions on Knowledge and Data Engineering, vol. 36, no. 2, pp. 913-926, 2024.

[17] X. Dong, D. Thanou, L. Toni, M. Bronstein, and P. Frossard, "Graph Signal Processing for Machine Learning: A Review and New Perspectives," arXiv:2007.16061, 2020.

[18] R. Ramakrishna, H. T. Wai, and A. Scaglione, "A User Guide to Low-Pass Graph Signal Processing and Its Applications: Tools and Applications," IEEE Signal Processing Magazine, vol. 37, no. 6, pp. 74-85, 2020.

[19] Y. Shen, Y. Wu, Y. Zhang, C. Shan, J. Zhang, B. K. Letaief, and D. Li, “How Powerful is Graph Convolution for Recommendation?,” Proceedings of the 30th ACM International Conference on Information & Knowledge Management, pp. 1619-1629, 2021.

[20] J. Liu, D. Li, H. Gu, T. Lu, P. Zhang, L. Shang, and N. Gu, “Personalized Graph Signal Processing for Collaborative Filtering,” Proceedings of the ACM Web Conference 2023, pp. 1264-1272, 2023.

[21] P. Jinduk, S. Yongmin, and S. Wonyong, “Turbo-CF: Matrix Decomposition-Free Graph Filtering for Fast Recommendation,” Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 2672-2676, 2024.

[22] J. Xia, D. Li, H. Gu, T. Lu, P. Zhang, L. Shang, and N. Gu, “Hierarchical Graph Signal Processing for Collaborative Filtering,” Proceedings of the ACM Web Conference 2024, pp. 3229-3240, 2024.

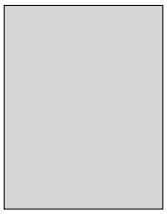
[23] F. M. Harper and J. A. Konstan, “The MovieLens Datasets: History and Context,” ACM Transactions on Interactive Intelligent Systems, vol. 5, no. 4, Article 19, pp. 1-19, 2015.

[24] M. Jamali and M. Ester, “A Matrix Factorization Technique with Trust Propagation for Recommendation in Social Networks,” Proceedings of the 4th ACM Conference on Recommender Systems (RecSys ’10), pp. 135-142, 2010.

[25] P. Massa and P. Avesani, “Trust-aware Recommender Systems,” Proceedings of the 2007 ACM Conference on Recommender Systems (RecSys ’07), pp. 17-24, 2007.

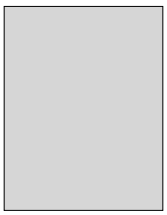
\

Authors



Kil Dong Hong received the B.S., M.S. and Ph.D. degrees in Computer Science and Engineering from Korea University, Korea, in 1989, 1991 and 2004, respectively

Dr. Hong joined the faculty of the at Korea University, Seoul, Korea, in 2008. He is currently a Professor in the Korea University. He is interested in parallel computing, internet and mobile computing, and cloud computing.



Kil Sun Hong received the B.S., M.S. and Ph.D. degrees in Computer Science and Engineering from Korea University, Korea, in 1989, 1991 and 2004, respectively

Dr. Hong joined the faculty of the at Hankook University, Seoul, Korea, in 2008. He is currently a Professor in the Korea University. He is interested in parallel computing, internet and mobile computing, and cloud computing.